

深層学習による疎なメッシュの高速3D再構築

鈴木 晴也

テンソル・コンサルティング株式会社

doprogramtpic@outlook.jp

2026 年 8 月 29 日

概要

本研究は、ボクセル占有表現に伴うメモリ・計算コストおよび量子化誤差を回避しつつ、3Dメッシュの構造（頂点・辺）を高い情報効率で表現する手法を提案する。提案法は、3D格子上に辺ベクトル場 V_e と頂点補正のオフセット場 V_o を定義し、局所ベクトル場からメッシュ辺を復元する。辺の端点順序問題を解消するために中点指向のベクトル配置を導入し、さらにnStep探索とstep一致判定により鋭角部や多接続部で生じる離散格子由来の情報欠落を抑制する。加えて、 V_e を単位ベクトルから初速度ベクトルへ拡張することにより復元計算を約半分に削減した。実験では、設計要素のアブレーションにより破綻率と復元速度の改善を確認した。さらに前述のアルゴリズムを使用して単一画像から3D再構築を推論するモデルではうまくいかなかった学習結果を整理し、損失設計や中間表現の不足が学習停滞の要因となる可能性を考察する。

キーワード: 単一画像, 3D再構築, OpenPose, ベクトル解析

1 はじめに

3D再構築は、ロボティクス, AR/VR, 自動運転, および3次元コンテンツ生成など多くの分野において重要な基盤技術である。特に単一画像から3D形状を推定する問題は、センサや撮影環境に制約のある実応用において高い需要がある。その一方で、単眼画像からは奥行き情報が直接観測できないため、本質的に ill-posed な問題として知られている。このため、多くの既存研究では、Time of Flight (TOF) センサーによる奥行き画像入力や多視点入力, あるいは高次元の中間表現を導入することで問題の緩和を試みてきた[16]。

単一画像からの3D再構築において広く用いられてきた表現の一つがボクセル表現である。ボクセル表現は正規格子上に定義されるため、畳み込みニューラルネットワーク (CNN) との親和性が高く、実装が容易であるという利点を持つ。しかし、高精度な形状を表現するためには高解像度のボクセルが必要となり、メモリおよび計算コストが急増するという課題がある。さらに、格子量子化に起因する位置誤差により、薄い構造や鋭いエッジといった幾何学的に重要な情報が曖昧化されやすい。

これらの問題を回避するため、点群、メッシュ、符号付距離関数 (SDF) など、様々な3D表現が提案されている。しかし、点群は明示的な接続関係を持たず、メッシュはトポロジや頂点順序が可変であるため、深層学習による教師付き学習において不安定になりやすい。また、SDFは高品質な形状を生成可能である一方、推論時に多数のサンプリングや後処理 (Ray Marching等) を必要とし、計算コストが高いという課題が残る。このように、情報効率・学習可能性・計算効率を同時に満たす3D表現は未だ確立されていないのが現状である。

一方、2次元人体姿勢推定の分野では、Part Affinity Fields (PAF) [?] に代表されるベクトル場による構造表現が成功を収めている。PAFは、キーポイント間の対応関係を局所的なベクトルとして表現することで、明示的な組合せ探索を行うことなく、安定的に全体構造の復元を可能にした。この考え方は、3次元形状を単なる占有や距離関数としてではなく、幾何構造の関係性そのものとして表現するという点で、3D再構築にも有効であると考えられる。

しかし、ベクトル場を用いた3次元幾何推定には、ボクセルや点群とは異なる固有の困難が存在する。第一に、ベクトル場は局所表現であるため、3次元空間において複数の辺や頂点が近接・交差する場合、情報の干渉が生じやすい。第二に、連続空間上に定義される幾何構造を有限解像度の格子上で表現することに起因する、量子化誤差と位置精度の問題がある。第三に、辺は端点の順序を持たない (無向である) にもかかわらず、単純なベクトル定義では教師信号が不定となり、学習可能性と幾何的一意性の両立が難しいという課題がある。

本研究では、これらの問題に対処するため、3D形状を頂点と辺からなる構造グラフとして捉え、3次元格子上に定義された **Edge-Offset Vector Field** と呼ぶ新しい表現を提案する。提案表現は、以下の2種類のベクトル場から構成される。

- (i) 辺の接続関係を表す辺ベクトル場 $\mathbf{V}_e$
- (ii) 格子量子化による誤差を補正するオフセットベクトル場 $\mathbf{V}_o$

これにより、高解像度ボクセルを用いることなく、サブボクセル精度の頂点位置と明示的なエッジ接続を同時に表現することが可能となる。

さらに、本研究の重要な特徴として、ベクトル場を3次元格子全体に一律に配置しない点が挙げられる。一般的な3Dベクトル場表現では、全格子点にベクトルを定義するため、形状と無関係な空間にも大量の冗長情報が含まれ、占有率が高くなる。これに対し本研究では、 $\mathbf{V}_o$ および $\mathbf{V}_e$ を辺の中点や端点近傍といった幾何学的に意味を持つ局所領域のみに配置し、それ以外の領域ではゼロもしくは無効値として扱う。この疎 (Sparse) な設計により、ベクトル場の実効占有率を大幅に低減し、情報干渉の抑制、学習の安定化、および計算効率の向上を同時に実現する。

また、辺表現においては、端点順序に依存しないよう、辺の中点を基準として双方向にベクトルを定義する。復元時には、中点から正負方向にベクトルを追跡し、両方向で整合した場合のみ辺として採用する対称的な判定を行う。この局所的な幾何制約は、単一画像からの推定において問題となる奥行きのもやもやを緩和し、誤った接続の発生を抑制する。さらに、複数の端点候補が存在する場合には、オフセットベクトルのユークリッド距離が最小となるもののみを選択するこ

とで、局所的な対応関係の曖昧性を低減する。

加えて、計算効率の観点から、辺ベクトルを単位ベクトルではなく端点までの初速度ベクトルとして表現する。これにより、復元時の近傍探索回数を削減し、ベクトル場に基づく幾何復元の計算コストを大幅に低減することができる。この設計は、疎なベクトル場表現の利点を最大限に活かす上で重要である。

本研究における実験では、単一画像から直接3D形状を学習する過程において、損失関数設計や中間表現の不足が学習を著しく困難にすることも示された。

本論文の貢献は以下の3点にまとめられる。

1. ボクセル占有に依らず、幾何学に基づいて形状を符号化する疎な3次元ベクトル場表現 (**Edge-Offset Vector Field**) を提案する。
2. ベクトル場による幾何推定に固有の問題を整理し、順序非依存な辺表現と対称的復元アルゴリズムによる解決策を示す。
3. 単一画像からの3D再構築を想定した広範な検討を通じて、表現設計の重要性と課題を明らかにする。

2 関連研究

2.1 Single-View 3D Reconstruction with Explicit Representations

単一画像からの3D再構築は、コンピュータビジョンの長年の課題である。深層学習の発展以前は、Shape-from-ShadingやShape-from-Textureといった幾何学的手法が主流であったが、これらはテクスチャや照明条件に強く依存していた。近年では、大規模データセットを用いたデータ駆動型のアプローチが主流となっている。

初期の深層学習ベースの手法では、3次元空間を正規格子に分割するボクセル表現 (**Voxel representation**) が広く用いられた[2]。ボクセルは3D畳み込みニューラルネットワーク (3D-CNN) を直接適用できるため実装が容易であるが、空間解像度の3乗に比例してメモリ消費量が増加する。Octreeなどの適応的データ構造を用いた手法[4]も提案されているが、依然として高解像度化には計算資源の制約が伴う。

点群 (**Point Cloud**) ベースの手法[5]は、ボクセルよりもメモリ効率が良く、詳細な形状を表現可能である。しかし、点群は点同士の接続関係 (トポロジ) を持たないため、サーフェス生成には別途メッシュ化処理が必要となる。

メッシュ (**Mesh**) ベースの手法[18]は、テンプレートメッシュを変形させることでトポロジを持つ形状を推定する。このアプローチは滑らかな表面を生成できるが、初期テンプレートのトポロジ (通常は球体) に拘束されるため、種数の異なる複雑な形状や、複数の分離した物体への対応が困難である。本研究のアプローチは、これら明示的表現の制約を克服し、任意のトポロジを持つ形状を、接続関係を含めて再構築することを目指すものである。

2.2 Implicit Neural Representations

明示的な形状表現の解像度制約を克服するため、陰関数表現 (**Implicit Representations**) が注目されている。Occupancy Networks[7]やDeepSDF[8]は、空間上の任意の点における占有確率や符号付距離関数 (SDF) をニューラルネットワークで回帰する。これにより、メモリ制約を受けずに無限の解像度で形状を表現可能とした。

また、Neural Radiance Fields (NeRF)[13]に代表されるボリウムレンダリング技術の発展により、多視点画像からの高精細な形状・外観復元が可能となっている。しかし、陰関数表現は推論時に形状を抽出するために、Marching Cubes法などの後処理や、空間内の多数の点に対するネットワーク評価 (Sampling) を必要とする。特に単一画像からの実時間応用を考えた場合、この計算コストは大きなボトルネックとなる。本研究で提案するベクトル場表現は、陰関数表現のような連続性を持ちつつも、グラフ構造を直接的に推論できるため、高価なサンプリング処理を回避できる利点がある。

2.3 Vector Fields and Structural Inference

幾何構造や接続関係を推定するために、ベクトル場 (Vector Field) を用いるアプローチは、主に2次元の画像認識タスクで成功を収めている。特に人体姿勢推定におけるPart Affinity Fields (PAF)[10]は、キーポイント間の接続方向をベクトル場として学習することで、ボトムアップに人物の骨格構造を復元する手法を確立した。

3次元領域においても、SDFの勾配場を利用したり、サーフェス上の流動場を推定する研究が存在する。しかし、これらは主に既存の3D形状の変形や微修正を目的としており、単一画像から「ゼロから (ab initio)」3D構造グラフ (頂点と辺) を構築するためにベクトル場を用いた例は少ない。PolyGen[11]のように頂点と面を系列として生成する手法もあるが、自己回帰モデルを用いるため推論速度に課題がある。

本研究の**Edge-Offset Vector Field**は、PAFの概念を3次元空間に拡張しつつ、3D固有の問題である量子化誤差をオフセットベクトルによって補正するものである。また、空間全体ではなく幾何学的特徴付近にのみ場を定義する「疎 (Sparse)」な設計を取り入れることで、3次元空間における計算効率と学習の安定性を両立させる点が、既存のベクトル場アプローチと大きく異なる。

3 提案手法 Edge-Offset Vector Field

本章では、本研究で提案する *Edge-Offset Vector Field* による3次元形状表現と、その復元アルゴリズムについて述べる。本手法は、3D形状を頂点と辺からなるグラフ構造として捉え、ボクセル占有を用いずに疎な3次元ベクトル場として符号化することを目的とする。

3.1 Problem Definition

入力として単一画像 $I \in \mathbb{R}^{H \times W \times 3}$ を与え、出力として3次元メッシュ $\mathcal{M} = (\mathcal{V}, \mathcal{E})$ を推定する問題を考える。ここで $\mathcal{V} = \{\mathbf{v}_i \in \mathbb{R}^3\}$ は頂点集合、 $\mathcal{E} = \{(i, j)\}$ は頂点間の辺集合である。

本研究では、 $\mathcal{M}$ を直接回帰する代わりに、3次元格子 $\Omega = \{1, \dots, H\} \times \{1, \dots, W\} \times \{1, \dots, D\}$ 上に定義された2種類のベクトル場として符号化し、これを復元する。

3.2 Edge-Offset Vector Field

提案表現は、以下の2つのベクトル場から構成される：

- 辺ベクトル場： $V_e : \Omega \rightarrow \mathbb{R}^3$
- オフセットベクトル場： $V_o : \Omega \rightarrow \mathbb{R}^3$

これらは3次元格子全体に一樣に定義されるのではなく、幾何構造が存在する局所領域のみに疎に配置される。

3.2.1 Offset Vector Field

オフセットベクトル場 V_o は、格子点 $\mathbf{p} \in \Omega$ から実際の連続空間上の頂点位置への補正を表す。頂点 $\mathbf{v}_i$ に最も近い格子点 $\mathbf{p}_i$ に対して、

$$V_o(\mathbf{p}_i) = \mathbf{v}_i - \mathbf{p}_i \quad (1)$$

と定義する。それ以外の格子点では $V_o(\mathbf{p}) = \mathbf{0}$ とする。この設計により、格子量子化による位置誤差をサブボクセル精度で補正可能となる。

3.2.2 Edge Vector Field

辺ベクトル場 V_e は、辺の接続関係を表現するためのベクトル場である。辺 $(i, j) \in \mathcal{E}$ に対して、その中点を


$$\mathbf{c}_{ij} = \frac{1}{2}(\mathbf{v}_i + \mathbf{v}_j) \quad (2)$$

と定義し、 $\mathbf{c}_{ij}$ に最も近い格子点 $\mathbf{p}_{ij}$ を求める。

本研究では、辺の端点順序に依存しないよう、中点を基準として双方向に辺ベクトルを定義する。端点方向ベクトルは以下で与えられる：

$$\mathbf{d}_{ij}^{(+)} = \mathbf{v}_i - \mathbf{c}_{ij}, \quad \mathbf{d}_{ij}^{(-)} = \mathbf{v}_j - \mathbf{c}_{ij} \quad (3)$$

これらを正規化して、端点までの距離情報を含む初速度ベクトルとして用いる：



(a) Edge-Offset Vector Fieldの2次元投影 (b) Edge-Offset Vector Fieldの2次元投影図. 青色はオフセット, 青色はオフセット、橙色は辺ベクトル場ト、橙色は辺ベクトル場を表す。
を表す。

$$V_e(\mathbf{p}_{ij}) = \{\mathbf{d}_{ij}^{(+)}, \mathbf{d}_{ij}^{(-)}\} \quad (4)$$

それ以外の格子点では $V_e(\mathbf{p}) = \mathbf{0}$ とする。

3.3 Sparse Occupancy of Vector Fields

一般的な3Dベクトル場表現では、全格子点にベクトルを定義するが、本研究では幾何構造に直接対応する格子点のみに V_e, V_o を配置する。この結果、ベクトル場の実効占有率は

$$\rho = \frac{|\{\mathbf{p} \mid \|V_e(\mathbf{p})\| > 0 \vee \|V_o(\mathbf{p})\| > 0\}|}{|\Omega|} \quad (5)$$

となり、 $\rho \ll 1$ が成り立つ。この疎な設計は、情報干渉の抑制、学習の安定化、および復元計算の高速化に寄与する。

3.4 Edge Reconstruction

予測されたベクトル場 $\hat{V}_e, \hat{V}_o$ からメッシュを復元する。まず、 $\hat{V}_o$ が非ゼロである格子点から頂点候補を生成する：

$$\hat{\mathbf{v}} = \mathbf{p} + \hat{V}_o(\mathbf{p}) \quad (6)$$




図2: Edge-Offset Vector Fieldの2次元投影図.青色はオフセット、橙色は辺ベクトル場を表す.

次に、 $\hat{V}_e$ が非ゼロである格子点 $\mathbf{p}_c$ を辺の中点候補として扱う． $\hat{V}_e(\mathbf{p}_c)$ に含まれる正負方向ベクトルを用いて、以下の手順で辺を復元する：

1. 中点 $\mathbf{p}_c$ から $\pm \hat{V}_e(\mathbf{p}_c)$ の方向に追跡ベクトルを更新する
2. 正負両方向の追跡先26近傍で得られたオフセットベクトルまでのステップ数が正負両方向で一致する場合、オフセットベクトル候補とする
3. オフセットベクトル候補から追跡ベクトルとのL2距離が最も小さいを採用
4. 採用された二つのから辺を復元する

この対称性判定により、近接・交差する辺が存在する場合でも誤った接続を抑制できる．

3.5 Computational Efficiency

辺ベクトルを単位ベクトルではなく初速度ベクトルとして表現することで、復元時の近傍探索回数を削減できる．これにより、総探索回数は従来の単位ベクトル表現と比較して約半分に削減され、1フレームあたりの復元計算時間が大幅に短縮される．




図3: モデルアーキテクチャ

3.6 モデルアーキテクチャ

3.6.1 MobileNetV4-FPN Architecture

MobileNetV4-FPNは、高い推論効率と精度のバランスを追求したバックボーン・ネック構成を採用している。本アーキテクチャは、最新のモバイル向けネットワークである MobileNetV4 を特徴抽出器 (Backbone) とし、そのマルチスケールな特徴を統合する Feature Pyramid Network (FPN) で構成される。本実装では、バックボーンの最後の3つのステージ（一般にストライド 8, 16, 32 に相当）から特徴マップ $\{C_3, C_4, C_5\}$ を抽出する。

■Feature Pyramid Network (FPN) 抽出されたマルチスケールな特徴は、FPNを介してトップダウンパスウェイと側方向連結 (Lateral Connection) により統合される。FPNの各レベルでは以下の処理が行われる：

1. **Lateral Connection:** 各ステージ C_i に対し、 1×1 畳み込みを適用してチャンネル数を $d = 256$ に統一。
2. **Top-down Pathway:** 低解像度でセマンティックに強い上位レベルの特徴を、最下層へ向かって最近傍補間 (Nearest Neighbor Interpolation) によりアップサンプリングし、下位レベルの側方向特徴と加算融合。
3. **Smoothing:** 融合後の特徴に対し、 3×3 畳み込みを適用してエイリアシング効果を抑制し、最終的なピラミッド特徴 $\{P_3, P_4, P_5\}$ を生成。

本システムでは、これらの統合された特徴のうち、最も解像度が高く詳細な空間情報を保持する第1レベルの特徴 (P_3 相当) を、後続のタスク (ClassNet, MeshNet, CGRegNet) への共通入力として用いる。これにより、計算負荷を抑えつつ、微細な物体構造の復元に必要な局所的・大域的コンテキストの両立を実現している。

3.6.2 ClassNet Architecture

ClassNetは、入力された特徴マップから物体のセグメンテーションマップを推定し、各画素に対してカテゴリ分類を行う。本モデルは、共通の局所特徴を抽出するStem部と、6つの投影方向 (xy, yz, zx 平面の各正負方向) に対応した分類ヘッドで構成される。Stem部は、畳み込み層、バッチ正規化、および残差ブロック (Residual Block) のスタックで構成され、受容野を広げつつ非線形表現能力を高めている。各分類ヘッドは 1×1 畳み込み層により、チャンネル数をクラス数 N_{class} へと変換し、各視点におけるオブジェクトの存在範囲とカテゴリを確率マップとして出力する。

3.6.3 Loss Function for ClassNet

ClassNetの学習には、各投影方向における多クラス交差エントロピー誤差（Cross Entropy Loss）の総和を用いる。正解ラベル（Ground Truth）は、3Dメッシュの各面を対応する平面へ投影し、手前にある面のクラスIDで各画素を塗りつぶすことで生成される。損失関数 $\mathcal{L}_{class}$ は次のように定義される：

$$\mathcal{L}_{class} = \sum_{d \in \{xyp, xym, yzp, yzm, zxp, zxm\}} \text{CrossEntropy}(\mathbf{P}_d, \mathbf{T}_d) \quad (7)$$

ここで、 $\mathbf{P}_d$ は方向 d における予測ロジット、 $\mathbf{T}_d$ は投影によって生成されたターゲットマップを表す。

3.6.4 MeshNet Architecture




図4: 2D平面上の各視点のOffset/Target Vector Field

MeshNetは、Convolutional Pose Machines (CPM)[3] に着想を得た多段階（Multi-stage）構造を採用しており、2D平面上のエッジを表すベクトル場を推定する。モデルは初期段階の Stage 1 と、前段の出力を受けて情報を洗練する Stage 2 から Stage 6 の再帰的な構成をとる。各ステージでは、エッジへのオフセットベクトル（Offset）と、エッジの端点を指すターゲットベクトル

ル (Target)、およびエッジの存在を示すマスク (Mask) を各視点 (xy, yz, zx) ごとに予測する(図4). これにより、複雑なトポロジを持つメッシュのエッジ構造を、2D投影面上でロバストに表現することが可能となる.

3.6.5 Loss Function for MeshNet

MeshNetの損失関数は、疎なベクトル場に対する回帰性能を向上させるため、検出 (存在確率)、方向 (角度精度)、強度 (長さ) の3つの観点から最適化される. 各ステージ s において、予測値 (マスクのロジット p_{logit} 、ベクトル v_{pred}) と、正解 (バイナリマスク M_{gt} 、ベクトル v_{gt}) を用いて以下の **Sparse Vector Field Loss** $\mathcal{L}_{svf}$ を計算する.

1. **Detection Loss** ($\mathcal{L}_{det}$): エッジの有無を判定する Focal BCE 損失. ここで、正解ラベルにはガウシアン拡散を施したソフトターゲット $\hat{M}$ を用いる. 実装に基づき、予測確率 p_t と重み係数 α_t をターゲット値で補間し、BCE項にスケーリングを行う形式で定義される:

$$\mathcal{L}_{det} = \frac{1}{N} \sum_{i=1}^N \alpha_{t,i} (1 - p_{t,i})^\gamma \cdot \mathcal{L}_{BCE}(p_i, \hat{M}_i) \quad (8)$$

ここで、各項は次のように定義される.

$$p_i = \sigma(p_{logit,i}) \quad (9)$$

$$\mathcal{L}_{BCE}(p_i, \hat{M}_i) = - \left[\hat{M}_i \log(p_i) + (1 - \hat{M}_i) \log(1 - p_i) \right] \quad (10)$$

$$p_{t,i} = \hat{M}_i p_i + (1 - \hat{M}_i)(1 - p_i) \quad (11)$$

$$\alpha_{t,i} = \hat{M}_i \alpha + (1 - \hat{M}_i)(1 - \alpha) \quad (12)$$

ここで $\sigma(\cdot)$ はシグモイド関数、 α はクラスバランスを調整する重み、 γ は難易度の高いサンプルを重視するフォーカシング・パラメータである. ターゲット $\hat{M}$ は、膨張 (Dilation) とガウシアンカーネル ($\sigma = 1.0$) の適用により、エッジ近傍に対してもなだらかな正例ラベルを付与する.

2. **Direction Loss** ($\mathcal{L}_{dir}$): ベクトルの向きの精度を評価する Angular Huber 損失. 予測ベクトルと正解ベクトルをそれぞれ正規化した $\hat{v}_{pred}, \hat{v}_{gt}$ 間のなす角 $\theta = \arccos(\hat{v}_{pred} \cdot \hat{v}_{gt})$ に対して定義されよう:

$$\mathcal{L}_{dir}(\theta) = \begin{cases} \frac{1}{2\delta} \theta^2 & \text{if } \theta \leq \delta \\ \theta - \frac{\delta}{2} & \text{otherwise} \end{cases} \quad (13)$$

この損失は、正解マスクが有効 ($M_{gt} > 0$) かつベクトルのノルムが閾値 τ を超える画素においてのみ計算される. $\delta = 0.2$ 程度の閾値を用いることで、微小な角度誤差に対しては二次関数的 (L2)、大きな誤差に対しては線形的 (L1) に反応し、外れ値に対してロバストな学習を可能にする.

3. **Magnitude Loss ($\mathcal{L}_{mag}$):** ベクトルの長さを評価する Log-space L_1 損失. 極端なスケールの変動に耐性を持たせるため、対数空間での絶対誤差を計算する：

$$\mathcal{L}_{mag} = |\log(\|v_{pred}\| + \epsilon) - \log(\|v_{gt}\| + \epsilon)| \quad (14)$$

これにより、エッジの長さ（強度）が小さい領域から大きい領域まで、相対的な誤差として等価に評価される。

4. **Negative Suppression Loss ($\mathcal{L}_{neg}$):** 正解エッジが存在しない領域 ($M_{gt} = 0$) において、不要なベクトル出力を抑制する項. 予測ベクトルのノルムをペナルティとして与える：

$$\mathcal{L}_{neg} = \frac{1}{N_{neg}} \sum_{i \in neg} \|v_{pred,i}\|^\gamma \cdot \|v_{pred,i}\|^2 \quad (15)$$

ここで $\|v_{pred}\|^\gamma$ は、誤って大きな強度が予測された「強い負例」をより厳しく抑制するための重みとして機能する。また、計算効率化のために負例サンプルの中から損失の大きい Top- $k\%$ のみを選択的に学習に用いることも可能。

最終的な MeshNet の損失関数 $\mathcal{L}_{mesh}$ は、全ステージ S における各損失の重み付き和として以下のように定義される：

$$\mathcal{L}_{mesh} = \sum_{s=1}^S \left(\beta \mathcal{L}_{det}^{(s)} + \alpha (\lambda_{dir} \mathcal{L}_{dir}^{(s)} + \lambda_{mag} \mathcal{L}_{mag}^{(s)}) + \beta \mathcal{L}_{neg}^{(s)} \right) \quad (16)$$

実装上のデフォルト値は $\alpha = 1.0, \beta = 10, \lambda_{dir} = 1.0, \lambda_{mag} = 1.0$ であり、検出および負例抑制 (β) に高い重みを置くことで、スパースな構造の再現性を図った。

3.6.6 CGRegNet Architecture

CGRegNetは、三面図（Front, Side, Top）から得られる2D特徴を3Dボクセル空間へと変換・融合するアーキテクチャを備えている。まず、TripleViewEncoder により各視点の特徴を独立に抽出し、LowRankVoxelFusion モジュールにおいて低ランク近似を用いたボクセル融合（Low-rank Voxel Fusion）を行う。具体的には、アインシュタイン和（Einstein Summation）を用いることで、メモリ消費を抑えつつ 2D 特徴から 3D 特徴ボリュームを生成する。生成された 3D 特徴に対して 3D 畳み込みを適用し、3次元空間におけるオフセットベクトルおよびターゲットベクトルを直接推定する。

3.6.7 Loss Function for CGRegNet

CGRegNetの学習には、ボクセルベースのベクトル場損失に加え、形状の幾何学的整合性を担保する幾何損失を組み合わせた複合的な損失関数を用いる.：

$$\mathcal{L}_{total} = \lambda_{off} \mathcal{L}_{offset} + \lambda_{tgt} \mathcal{L}_{target} + \lambda_{cham} \mathcal{L}_{chamfer} + \lambda_{iou} \mathcal{L}_{IoU3D} \quad (17)$$

- $\mathcal{L}_{offset}, \mathcal{L}_{target}$: **Sparse Vector Field Loss**を3D空間に拡張したもの.3次元の向きと距離を評価する.
- $\mathcal{L}_{chamfer}$: 推定された頂点集合と正解メッシュの表面点群との間の Chamfer Distance.形状全体の近接性を評価する.
- $\mathcal{L}_{IoU3D}$: 3Dボクセル表現、またはサンプリングに基づく 3D IoU 損失.体積的な一致度を評価する.

これにより、局所的なエッジ精度と大域的な形状の正確性の両立を図っている.

4 検証

4.1 Edge-Offset Vector Field

各ベクトル場の形状は 80^3 に設定した.

4.1.1 復元結果

正解ベクトル場からの復元結果の例を以下に示す. 復元速度は1枚当たり約30ミリ秒だった.




図5: 復元結果

4.2 モデル学習

学習データはSUN RGB-D[1]の1/10サンプリングしたものを使用した. ラベル一覧を以下に示す. (表5c

表1: SUNRGBD 21クラス一覧 (4列)

bathtub	bed	bookshelf	box
chair	counter	desk	door
dresser	garbage bin	lamp	monitor
night stand	pillow	sink	sofa
table	tv	toilet	others
background			

4.2.1 学習結果

モデルの学習結果はClassNet以外はアンダーフィッティングになった.(表1




図6: モデル学習結果.ClassNet(左) MeshNet(中央) CGRegNet(右).

4.3 考察

図5cで他と十分に離れているオブジェクトは図5bでも復元できていることが分かる.一方で、頂点同士が非常に近いオブジェクトは26近傍搜索時(図5a)に情報干渉してしまう.更に、この例では 80^3 の領域を十分に使えていないため有効な解像度が落ち、結果として情報干渉が起きやすくなっていることが分かった.モデル学習では、ClassNetの多方向セマンティックセグメンテーションの学習は上手くいっていることが分かる.一方でこのClassNetの特徴量から潜在的にオブジェクトのエッジ情報を取得して、更に**Sparse Vector Field Loss**を用いることでMeshNet/CGRegNetが疎なベクトル場を表現することが可能になると期待していたが、結果としてこのモデルアーキテクチャ/損失関数設計では表現習得不可能なことが分かった.

5 結論

高速かつ正確な3D再構築を実現するために、占有率の低い疎なベクトル場からメッシュを復元するアルゴリズム**Edge-Offset Vector Field**、また、単眼画像から3D再構築を行うモデルアーキテクチャと**Sparse Vector Field Loss**を提案した。結果としては、復元アルゴリズムでは頂点同士が近い、局所的な場所に密集している場合に情報干渉が発生してしまうことが分かった。更に、モデルの学習結果ではこの疎なベクトル場の表現を習得不可能なことが分かった。

5.1 今後の課題

Edge-Offset Vector Fieldでは26近傍を使わず、ユークリッド的手法に代替させたい。また有効な解像度を可変的に最大化する手法を検討する必要がある。モデルアーキテクチャ及び**Sparse Vector Field Loss**では疎な教師ベクトル場にオーバフィッティングできるように改善を加える必要がある。

参考 11/20最新手法)META SAM3D object [22]。

参考文献

- [1] S. Song, S. P. Lichtenberg, and J. Xiao, "SUN RGB-D: A RGB-D scene understanding benchmark suite," in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 567-576.
- [2] C. B. Choy, D. Xu, J. Gwak, K. Chen, and S. Savarese, "3D-R2N2: A Unified Approach for Single and Multi-view 3D Object Reconstruction," in *European Conference on Computer Vision (ECCV)*, 2016, pp. 628-644.
- [3] Shih-En Wei, Varun Ramakrishna, Takeo Kanade, and Yaser Sheikh, "Convolutional Pose Machines," in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 4724-4732.
- [4] M. Tatarchenko, A. Dosovitskiy, and T. Brox, "Octree Generating Networks: Efficient Convolutional Architectures for High-Resolution 3D Outputs," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [5] H. Fan, H. Su, and L. J. Guibas, "A Point Set Generation Network for 3D Object Reconstruction From a Single Image," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [6] X. Sun, J. Wu, X. Zhang, Z. Zhang, C. Zhang, T. Xue, J. B. Tenenbaum, and W. T. Freeman, "Pix3D: Dataset and Methods for Single-Image 3D Shape Modeling," in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp.

2974-2983.

- [7] L. Mescheder, M. Oechsle, M. Niemeyer, S. Nowozin, and A. Geiger, "Occupancy Networks: Learning 3D Reconstruction in Function Space," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [8] J. J. Park, P. Florence, J. Straub, R. Newcombe, and S. Lovegrove, "DeepSDF: Learning Continuous Signed Distance Functions for Shape Representation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [9] G. Gkioxari, J. Johnson, and J. Malik, "Mesh R-CNN," in *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 9784-9794.
- [10] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei, and Y. Sheikh, "Openpose: Realtime multi-person 2d pose estimation using part affinity fields," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, no. 1, pp. 172-186, 2019.
- [11] C. Nash, Y. Ganin, S. M. A. Eslami, and P. Battaglia, "Polygen: An autoregressive generative model of 3d meshes," in *International Conference on Machine Learning (ICML)*, 2020, pp. 7220-7229.
- [12] C. Zhang, Z. Cui, Y. Zhang, B. Zeng, M. Pollefeys, and S. Liu, "Holistic 3D Scene Understanding From a Single Image With Implicit Representation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 8833-8842.
- [13] Z. Wang, S. Wu, W. Xie, M. Chen, and V. A. Prisacariu, "NeRF-: Neural radiance fields without known camera parameters," arXiv preprint arXiv:2102.07064, 2021.
- [14] C. Zhang, Z. Cui, Y. Zhang, B. Zeng, M. Pollefeys, and S. Liu, "Holistic 3D Scene Understanding From a Single Image With Implicit Representation", 2021.
Available: <https://github.com/chengzhag/Implicit3DUnderstanding>
- [15] D. Rukhovich, A. Vorontsova, and A. Konushin, "ImVoxelNet: Image to Voxels Projection for Monocular and Multi-View General-Purpose 3D Object Detection," in *2022 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2022, pp. 1265-1274.
- [16] "RGBD semantic segmentation", 2023.
Available: https://github.com/Yangzhangcst/RGBD-semantic-segmentation?utm_source=chatgpt.com
- [17] S. Du, W. Wang, R. Guo, R. Wang, and S. Tang, "AsymFormer: Asymmetrical Cross-Modal Representation Learning for Mobile Platform Real-Time RGB-D Semantic Segmentation," in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2024, pp. 7608-7615.
- [18] S. Zhang, B. Jiang, K. He, J. Zhu, Y. Tai, C. Wang, Y. Zhang, and Y. Fu, "T-Pixel2Mesh:

- Combining global and local transformer for 3D mesh generation from a single image,” arXiv preprint arXiv:2403.13663, 2024.
- [19] OpenAI, ”ChatGPT”, 2025.
Available: <https://chat.openai.com> (Accessed: 2025-09-23).
- [20] B.-W. Yin, J.-L. Cao, M.-M. Cheng, and Q. Hou, ”DFormerv2: Geometry Self-Attention for RGBD Semantic Segmentation,” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025, pp. 19345-19355.
- [21] Y. Mao, Y. Chen, Z. Qian, and J. Zhang, ”EACNet: Efficient Asymmetric Cross-Modal RGB-D Semantic Segmentation Network for Indoor Robotic Perception,” in *2025 IEEE 14th Data Driven Control and Learning Systems (DDCLS)*, 2025, pp. 1078-1083.
- [22] ”meta SAM3D Object”, 2025.
Available: <https://github.com/facebookresearch/sam-3d-objects?tab=readme-ov-file>